2026 AI·빅데이터 인사이트 컨퍼런스

AGENDA 02 플랫폼

주최 COSS 빅데이터 | 주관 숙명여자대학교 빅데이터 혁신융합사업단

AI 에이전트로 다시 설계하는 빅데이터 활용

데이터 정의·계산 위치·나누는 방식을 설계하고, 실행 기록으로 검증한다

2026. 11. 6.(금) 15:00 · 포포인츠 바이 쉐라톤 조선 서울역 20층

황민호

카카오 AI Studio FDE 수석

『하네스 엔지니어링 with 클로드 코드』 저자

PRESENTER

황민호

robin.hwang

AI가 일할 환경을 설계하는 사람

> 프롬프트가 아니라,
> **시스템**을 만듭니다.

주요 활동

- 저서 — 『하네스 엔지니어링 with 클로드 코드』
  한빛미디어 · 2026
- 교육·강연 — 카카오 그룹 · 대학 · 정부 · 기업
  AI 실습형 강의 다수
- 오픈소스 — revfactory/harness ★ 9.3k
- 연구·리서치 — 멀티에이전트 · AI 정책 · Frontier 모델 분석
- 커뮤니티 — today-ai-news
  평일 08~20시 매 2시간 갱신

주요 경력

- 2009 **WIPRO** — 자동 SQL DBMS 테스트
- 2010 **KISTI** — 문장 패턴분석 · 온톨로지
- 2013 **DAUM** — 클라우드 서비스 · 검색
- 현재 **KAKAO** AI Studio FDE 수석 — 광고 · OLIVE · AI Studio

데브시스터즈 기술 블로그(박현기) · Databricks Metric View 도입기 · 2026-09-18 · 자체 글

Q 대시보드 숫자와 에이전트가 말한 숫자가 다르면 어느 쪽을 믿어야 하나

게임 회사의 분석 에이전트는 승률을 대시보드와 조금 다르게 답했다

데브시스터즈(게임 회사) 데이터 조직, 신규 게임 출시 직후의 사내 분석 에이전트

신규 게임 출시, 대시보드와 에이전트가 같은 지표를 계산

질문: 지난주 승률 상위 10개 쿠키 (게임 캐릭터)

상위 순서는 맞았지만 승률 숫자가 대시보드와 조금씩 달랐다



에이전트 목표를 받아 도구(SQL 실행 등)를 스스로 골라 여러 단계로 일하는 LLM 프로그램

같은 사례(데브시스터즈). 이탈한 사용자를 뺄지, 표본이 몇 건 이상이어야 셀지가 요청마다 달라졌다



"분석 에이전트가 지표를 매번 스스로 정의했습니다"

에이전트가 정제되지 않은 로그를 읽고 정제 기준을 매번 스스로 정했다

→ 정의를 에이전트가 정하면 숫자가 대시보드와 어긋났다

Sehanobish 외(Kensho) · arXiv 2610.03524 · 2026-10-02 · 자체 평가(논문)

Q 한 회사의 일인가, 흔한 일인가

금융 DB에서 생성된 SQL은 99% 실행됐지만 정답은 절반에 못 미쳤다

금융 AI 회사 Kensho 운영 DB의 실제 질문 359개. 질문을 SQL로 바꾸는 방법 7종, 같은 LLM

SQL 데이터베이스 질의 언어

→ **실행이 됐다는 것과 답이 맞다는 것은 다른 일이다**

99% 이상 실행된 SQL

50% 미만 정답률 (7종 모두)

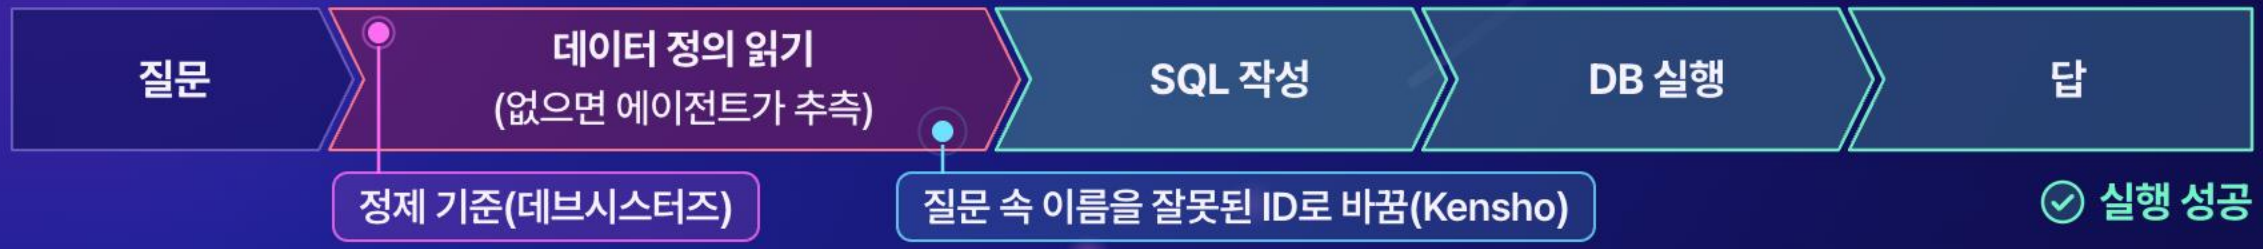


틀린 답 중 잘못된 ID(대상을 가리키는 번호)가 든 비율: 방법별 **64~96%**

데브시스터즈(2026-09-18) · Kensho(arXiv 2610.03524, 2026-10-02) · 앞 장 자료 종합

두 사례 모두 SQL 문법은 맞았고 에이전트가 스스로 고른 정제 기준과 ID가 틀렸다

질문이 답이 되기까지 다섯 단계 중 두 사례 모두 둘째 단계에서 틀렸고, 뒤 단계는 정상이었다



LLM 바깥 모델을 바꾸지 않고 설계할 수 있는 부분: 읽는 정의, 계산을 맡는 코드·DB, 에이전트 구성, 실행 기록

→ **그래서 LLM 바깥을 설계한다**

Q LLM 바깥에서 무엇을 설계하나

데이터 정의, 계산 위치, 나누는 방식을 설계하고 실행 기록으로 검증한다

① 데이터 정의
에이전트가 읽는 테이블·지표 설명

② 계산 위치
날짜 해석·집계를 어디서 하나
(에이전트·코드·DB)

③ 나누는 방식
에이전트와 작업을 어떤 기준으로 나누나

④ 실행 기록으로 검증 답과 기록을 함께 채점하고 여러 번 돌린다

실행 기록 에이전트가 무엇을 읽고 어떤 도구를 몇 번 불러 어떤 답을 냈는지 남긴 기록

다음: 2026년 11월 현황

02

SECTION 02

2026년 11월

에이전트를 만들고 운영하는 조직은 얼마나 되나

현재 시점 · 자료 4건

① 데이터 정의

② 계산 위치

③ 나누는 방식

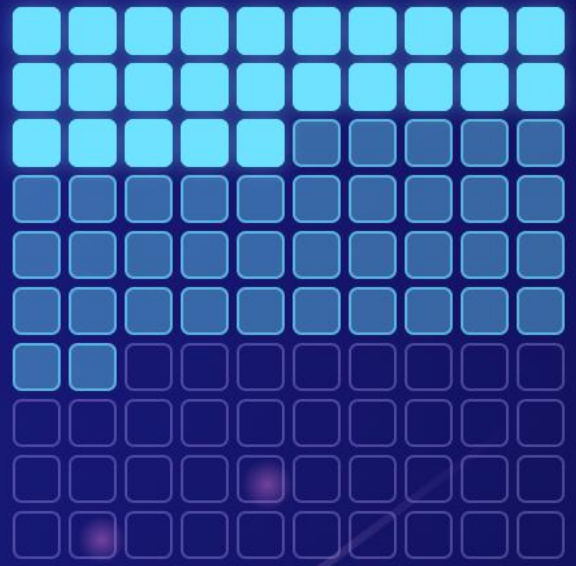
④ 실행 기록으로 검증

Q 에이전트를 만드는 기업은 얼마나 되나

미국 대기업 경영진 314명 중 62%가 에이전트를 구축·배포·개발 중이라고 답했다

KPMG 미국 Q3 조사(2026-07~08), 매출 10억 달러 이상 기업. 세 답을 합친 값

→ 넷 중 하나는 여러 에이전트로 나눈 구성을 시도한다



개발·구축·배포 중 응답의 합

62%

전체 314명 중

25%

멀티에이전트 개발·구현 중

멀티에이전트 역할을 나눈 에이전트 여러 개가 결과를 주고받으며 한 작업을 처리하는 구성

KPMG International · Global AI Pulse Q2 2026 · 2026-06-24 · 설문(응답자 자기 보고)

Q 만든 에이전트는 계속 늘었나 — 앞 장보다 먼저 한 다른 조사

기업 리더 2,145명 중 49%가 비용이 가치를 넘겨 에이전트 배포를 줄이거나 미루거나 멈췄다고 답했다

다른 조사: KPMG 국제 조사(2026-04~05), 20개국 기업 리더 2,145명

응답자 중 배포를 줄임 **24%**

49%

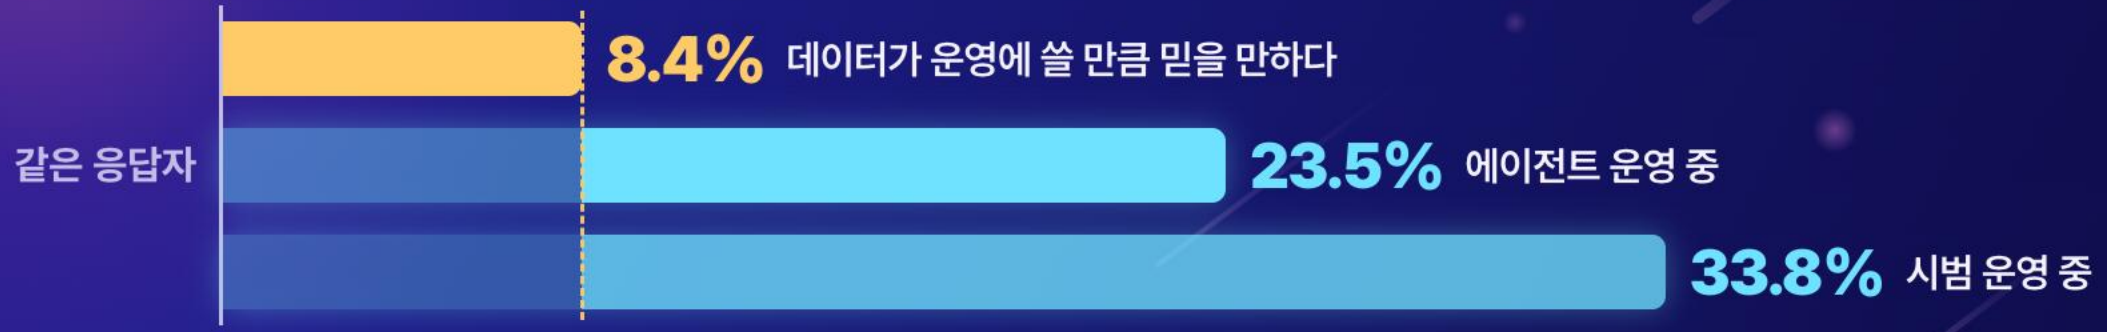
응답자 중 미루거나 멈춤 **25%**

→ 만드는 일보다 비용이 효과를 넘지 않게 하는 일이 과제가 됐다

IT Brief(The Modern Data Company 설문) · AI agents outpace trust in enterprise data · 2026-08-20 · 업체 설문 중간 결과

Q 에이전트에 넣을 데이터는 준비됐나

데이터 관리 업체 설문 중간 결과, 66개국 실무자 540건 이상

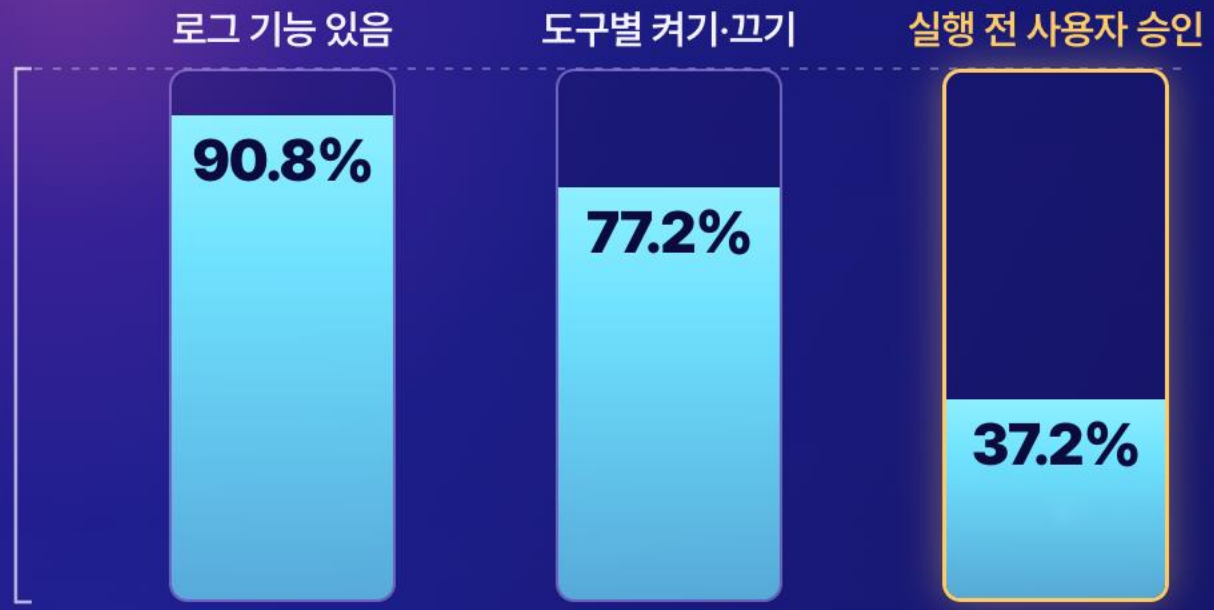


데이터를 믿는다는 응답 8.4%보다 에이전트를 운영 중이라는 응답 23.5%가 많았다

→ 에이전트 운영 중 응답(23.5%)이 데이터를 믿는다는 응답(8.4%)의 약 2.8배다

Majeed 외(NYU 아부다비) · An Empirical Study of MCP Applications · arXiv 2607.25635 · 2026-07-28 · 공개 저장소 분석

앱 1,723개 중



Q 도구를 붙인 에이전트는 실행 전에 멈춰 묻나

공개 MCP 앱 1,723개 중 도구 실행 전 승인 단계를 둔 앱은 37.2%였다

NYU 아부다비, MCP 규격으로 도구를 연결한 GitHub 공개 앱 1,723개를 LLM으로 분류

MCP 에이전트에 외부 도구를 연결하는 공통 규격

→ **앱의 90.8%는 로그를 남긴다. 그 기록으로 무엇을 확인할지는 「실행 기록으로 검증」에서 다룬다**

SECTION 03

03 데이터 정의

에이전트가 읽을 정의를 누가 쓰고 언제 고치나

1. 데이터 정의
2. 계산 위치
3. 나누는 방식
4. 실행 기록으로 검증

Q 회사 테이블 설명을 적어 주면 달라지나

Anthropic 데이터팀 · How Anthropic enables self-service data analytics with Claude · 2026-06-03 · 판매사 자체 측정

Anthropic 데이터팀은 회사 지식 스킬 없이는 자체 평가 정확도 21%를 넘지 못했다

사내 직원의 업무 분석 질문에 Claude 에이전트가 답하게 한 팀. 문항 수 비공개

스킬 에이전트가 작업 전에 읽는 절차·참고 문서 묶음(SKILL.md 파일)



사내 분석 질문을 에이전트에 맡김

스킬 없음: 자체 평가

21% 이하

회사 테이블·지표 정의를 적은 스킬 추가:

95% 이상

Anthropic 데이터팀

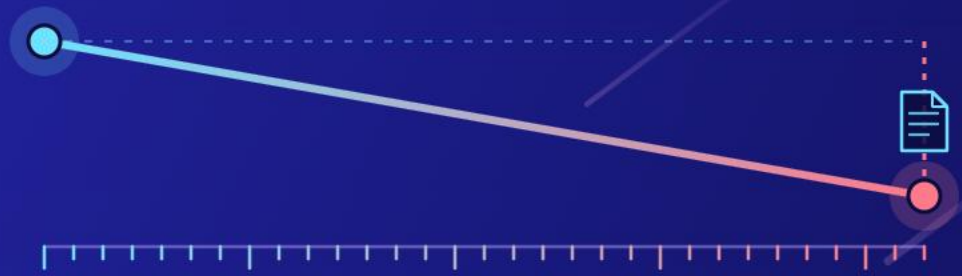
같은 팀 사내 평가셋. 데이터 모델이 매일 바뀌어 문서가 몇 주 안에 실제와 어긋났다

데이터 모델 테이블 구조와 관계를 정한 설계

사내 평가셋 정확도

사내 공개 직후

약 95%



한 달 뒤

약 65%

공개 후 경과

스킬 문서를 한 달 고치지 않자 정확도가 약 95%에서 약 65%로 내려갔다

→ 데이터 모델이 바뀌면 정의 문서도 같이 고쳐야 정확도가 유지된다

Anthropic 데이터팀 · How Anthropic enables self-service data analytics with Claude · 2026-06-03 · 판매사 자체 측정

데이터 모델을 고치는 PR의 약 90%에 스킬 수정이 같이 들어가게 됐다

스킬 문서를 데이터 모델 코드와 같은 저장소에 두고 코드 리뷰에서 함께 확인한다

PR 코드 변경을 검토받아 합치는 요청(pull request)



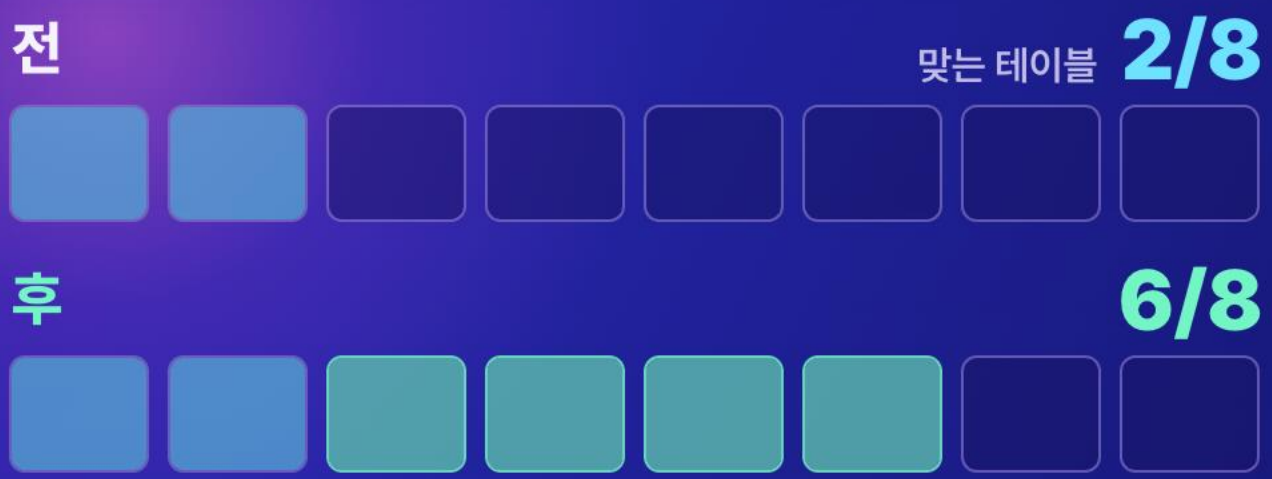
- 보고용 모델만 바꾼 PR은 코드 리뷰 때 자동 검사가 표시
- → 정의 문서도 데이터 모델 코드와 같은 PR·리뷰 절차로 고친다

토스 기술 블로그(김문수) · 실행은 도메인별로, 문맥은 한 레포에 · 2026-10-16 · 자체 측정(해커톤, 문항 8~9개)

Q 정의를 더하면 챗봇이 고르는 테이블이 달라지나

지식베이스에 지표 정의를 넣자 챗봇이 맞는 테이블을 고른 문항이 8개 중 2개에서 6개가 됐다

토스 데이터 웨어하우스팀의 분석 챗봇(에이전트), 5시간 해커톤. 정의를 보지 않은 사람의 질문 8개



설명형 질문(계산이 아닌 설명을 묻는 질문) 9개: 정답 2개 → 7개

지식베이스 챗봇이 답하기 전에 찾아 읽는 문서 모음(앞 장의 스킬과 같은 역할)

→ 문항 8개뿐이지만 Anthropic과 같은 방향이다

Necula(Alexandru Ioan Cuza University) · arXiv 2609.22222 · 2026-09-02 ·
통제 실험(단독 저자, 과제 30개)

Q 정의가 없으면 어떻게 틀리나

Eurostat(EU 통계청) 질의 30개, Claude Sonnet 5, 조건마다 3회(90번)



메타데이터 데이터 자체가 아니라 각 열의 의미·단위·구조를 적은 설명

메타데이터 없음: 답까지 나온 **71번 중 46번(64.8%)**



메타데이터 제공: **69번 중 23번(33.3%)**



메타데이터 없이 답까지 나온 실행의 64.8%가 오류 신호 없이 틀린 답이었다

→ 메타데이터가 없으면 오류 없이 그럴듯한 틀린 숫자가 나온다

발표자 제안 ·
근거 데브시스터즈(2026-09-18)·Anthropic 데이터팀(2026-06-03, 판매사 자체 측정) ·
참고 토스(2026-10-16)

규칙 1 RULE 01

에이전트가 읽을 데이터 정의는 사람이 쓰고 데이터 모델과 함께 고친다

근거 에이전트가 기준을 정하자 대시보드와 다른 숫자 (데브시스터즈) · 정의를 모델과 함께 고침(Anthropic PR **약 90%**)

참고 토스 8문항 중 2개 → 6개

정의 문서는 데이터 모델 코드와 한 저장소에, 함께 고친다



하네스 구현 정의 문서는 스킬의 `references` 폴더에, `SKILL.md`에는 읽을 문서와 순서만

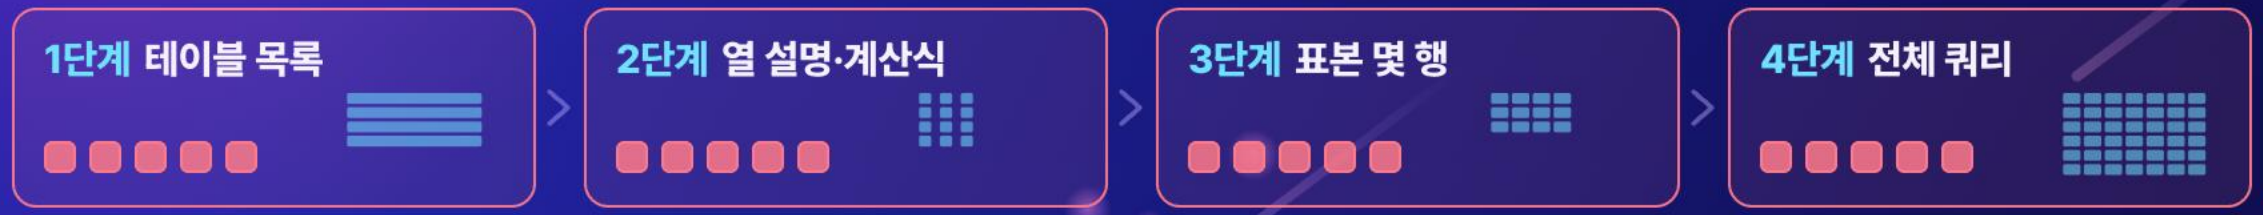
revfactory/harness 발표자가 만든 에이전트 팀 구성 플러그인(Claude Code용). 이 발표의 "하네스 구현"은 이 플러그인을 뜻한다

발표자 제안 · 참고 MCP 로드맵(2026-08-22) · Thumbtack(arXiv 2609.09182, 2026-08-28)

규칙 2 RULE 02

테이블 목록부터 차례로 읽고 탐색 단계마다 도구 호출 상한을 둔다

발표자 제안. 직접 비교한 연구는 없다. 뒤에 볼 Thumbtack 사례에서는 실행의 16%가 도구 호출 한도를 다 썼다



□□□□□ 상한 예: 5회(발표자 제안)

하네스 구현 처음엔 스킬 이름과 한 줄 설명만 읽고, 필요한 스킬의 본문만 이어 읽는다

04

SECTION 04

계산 위치

날짜 해석과 집계를 에이전트가 할지 코드와 DB에 맡길지

① 데이터 정의 ✓

② 계산 위치

③ 나누는 방식

④ 실행 기록으로 검증

ZDNet Korea(남혁우) · 웹케시 은행용 에이전트 기사 · 2026-10-07 · 회사 발표를 옮긴 기사

Q '2분기 실적'을 물으면 에이전트는 어느 기간을 계산하나

은행용 에이전트는 초기 테스트에서 '2분기 실적'의 날짜 범위부터 틀렸다

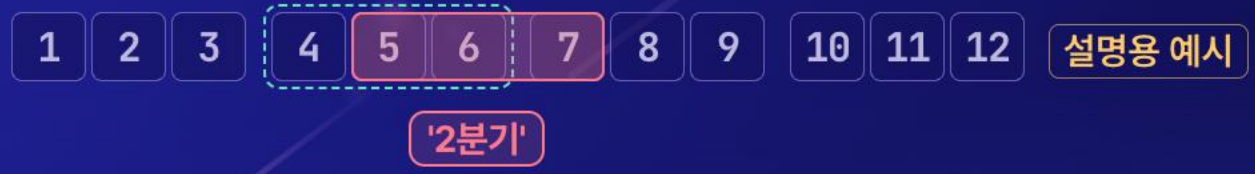
웹케시(기업·금융기관용 금융 소프트웨어 회사). 은행장·본부장과 영업점 지점장 130여 명이 쓰는 에이전트(기사)

전에는 요청서 작성부터 보고서까지 8단계였던 일을 질문 하나로

질문 1개

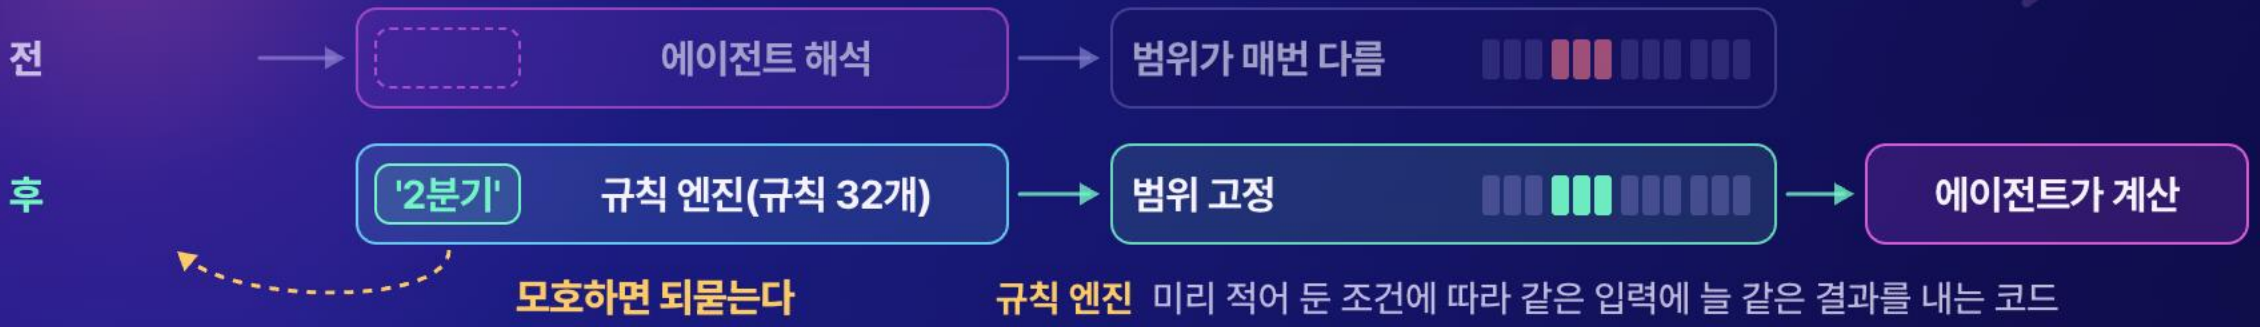
'2분기 실적' → 잘못된 날짜 범위, 근거 없는 증감률

은행 업무에 사용할 수 없는 수준



ZDNet Korea(남혁우) · 웹케시 은행용 에이전트 기사 · 2026-10-07 · 회사 발표를 옮긴 기사

업무 용어 317개를 DB 컬럼 879개에 연결, 계산 방식 128개는 규칙으로 정의. 적용 뒤 정확도는 기사에 없다



규칙 엔진 미리 적어 둔 조건에 따라 같은 입력에 늘 같은 결과를 내는 코드

날짜 해석은 규칙 32개로 고정하고 계산식 생성과 계산은 에이전트가 맡았다

→ 늘 같아야 하는 단계를 규칙으로 옮겼다

ZDNet Korea(남혁우) · 웹케시 은행용 에이전트 기사 · 2026-10-07 · 회사 발표를 옮긴 기사

Q 하루 2,400만 건이 적재되는 테이블은 어디서 계산하나

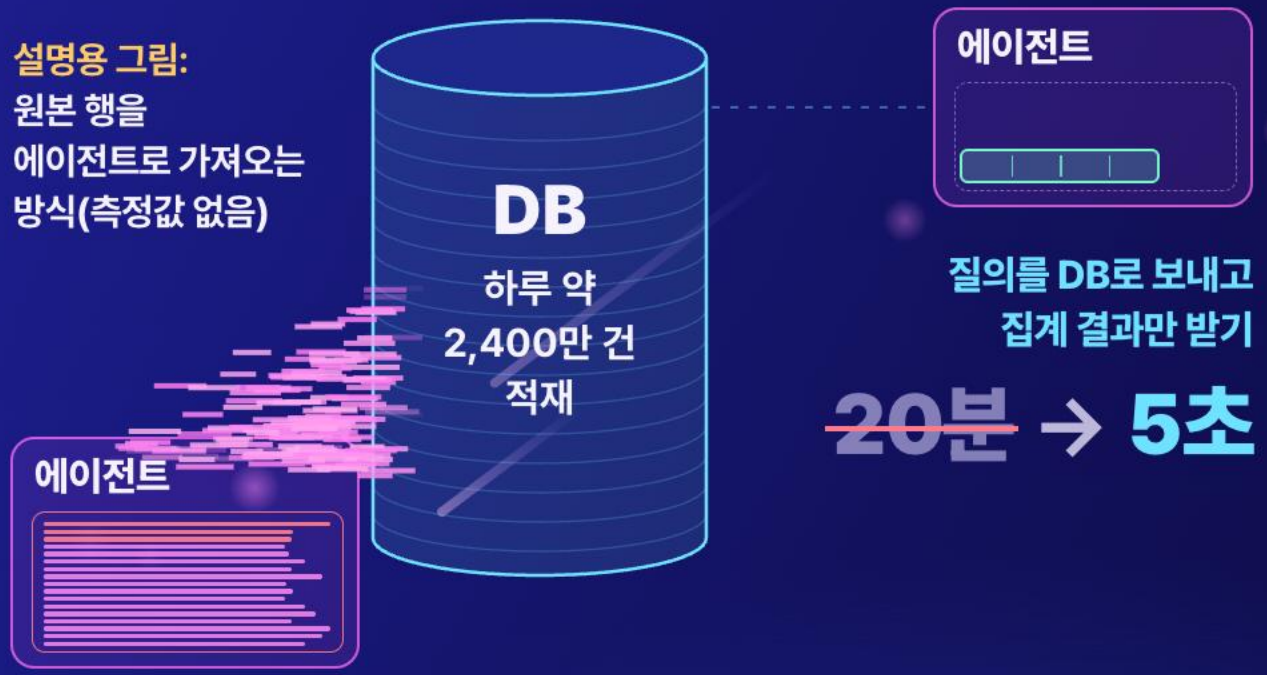
하루 2,400만 건이 적재되는 테이블에 옵티마이저 힌트를 넣자 조회가 20분에서 5초가 됐다

같은 사례. SQL에 테이블별 옵티마이저 힌트를 자동으로 넣었다

옵티마이저 힌트 데이터베이스에 실행 방법을 지정하는 SQL 주석

→ 데이터는 두고 질의를 보낸다

설명용 그림:
원본 행을
에이전트로 가져오는
방식(측정값 없음)



질의를 DB로 보내고
집계 결과만 받기

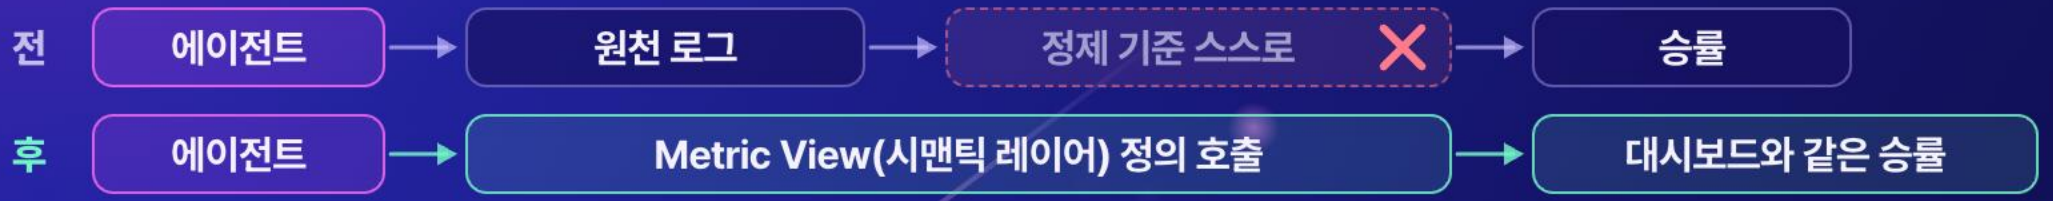
~~20분~~ → 5초

Q 처음에 본 데브시스터즈의 승률 차이는 어떻게 고쳤나

승률 계산을 에이전트에서 시맨틱 레이어로 옮기자 대시보드와 같은 값이 나오고 토큰·비용은 약 절반이 됐다

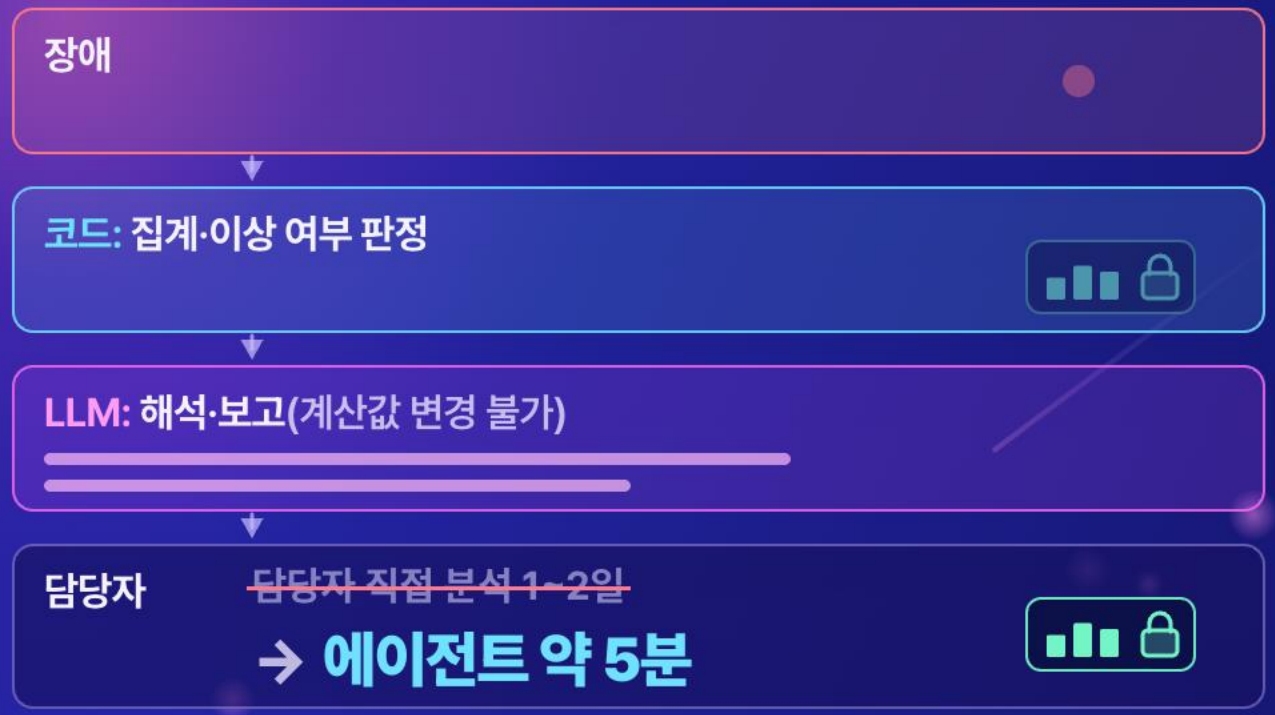
정제는 별도 레이어에서 끝내고, 승률 정의를 Databricks Metric View에 두었다

시맨틱 레이어 지표의 계산식·조건을 한곳에 정의해 두고 그 정의로 값을 내주는 층



같은 질문 세트: 토큰(LLM 글자 단위)·비용 약 절반 답까지 응답 횟수 30% 감소

→ 숫자를 셀 기준이 하나가 됐다. 정확도 측정값은 공개되지 않았다



Q 계산과 해석을 한 에이전트 안에서 나눌 수 있나

계산과 판정은 코드가, 해석은 LLM이 맡자 장애 분석이 1~2일에서 약 5분이 됐다

CJ올리브영 글로벌 프로모션 운영 조직. 소요 시간만 비교

→ 시간은 줄었지만 답의 정확도는 재지 않았다

규칙 3 RULE 03

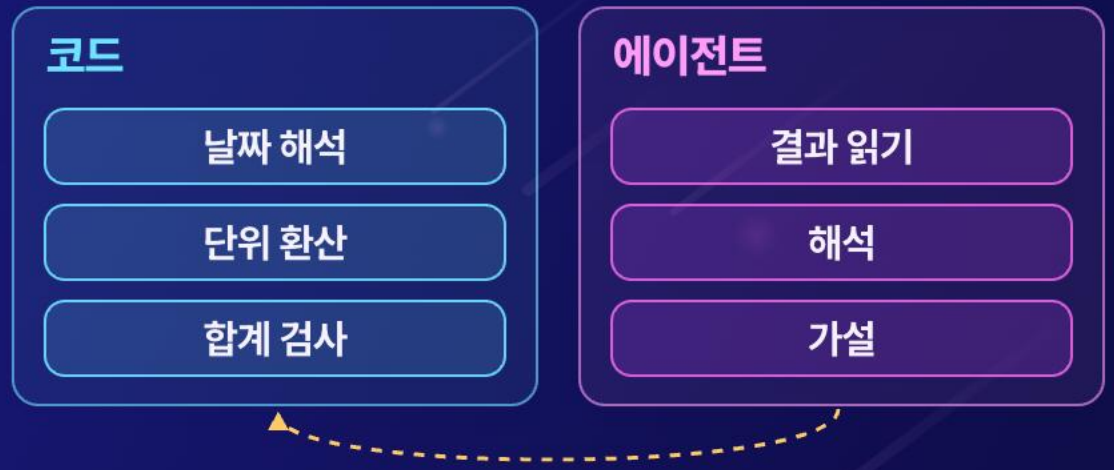
결과가 늘 같아야 하는 단계는 에이전트 대신 코드가 맡는다

근거:

웹케시(날짜 해석 → 규칙 32개),

CJ올리브영(집계·판정 → 코드).

집계는 규칙 4



하네스 구현: 계산 코드는 스킬의 `scripts` 폴더에 두고, 에이전트는 실행해 결과만 받는다

발표자 제안 · 근거 토스(2026-10-16) · 데브시스터즈(2026-09-18) · 웹케시(2026-10-07) · revfactory/harness 2.1.0 에이전트 정의 형식(2026-09-26)

규칙 4 RULE 04

계산은 데이터 시스템에서 하고 에이전트는 집계 결과만 읽는다

데이터 시스템 = DB·시맨틱 레이어.
근거: 토스 계산 질문 11개(8문항과 다른 묶음), 시맨틱 레이어 SQL 실행 → 9개 정답

> **원본 행을 읽지 않는다. 계산식은 시맨틱 레이어 정의 호출, 결과 행 수 상한**

설명용 예시

```
## 실행 제약
- SELECT만
- 1,000행 이하
```



참고: 데브시스터즈 토큰·비용 약 절반 · 웹케시 DB 안에서 조회(힌트로 20분 → 5초)

05

SECTION 05

나누는 방식

에이전트를 몇 개로, 작업을 무엇 단위로 나누나

① 데이터 정의 ✓

② 계산 위치 ✓

③ 나누는 방식

④ 실행 기록으로 검증

Sethuraman·Asokan(ZS Associates) · Why We Killed Our Multi-Agent Pipeline · 2026-07-02 · 자체 보고(주최 측 자막 확인)

Q 분석가가 하던 네 단계에 에이전트를 하나씩 붙이면 어떻게 되나

ZS는 처방 변화 분석을 조율 에이전트 1개와 분석 에이전트 4개로 나눴다

제약사 영업 분석 회사 ZS. 처방 변화의 원인 분석과 영업 조치 제안

분석 단계마다 에이전트 하나씩 + 조율 에이전트



결과물: 신호·원인·조치·전망을 한 묶음으로 보고

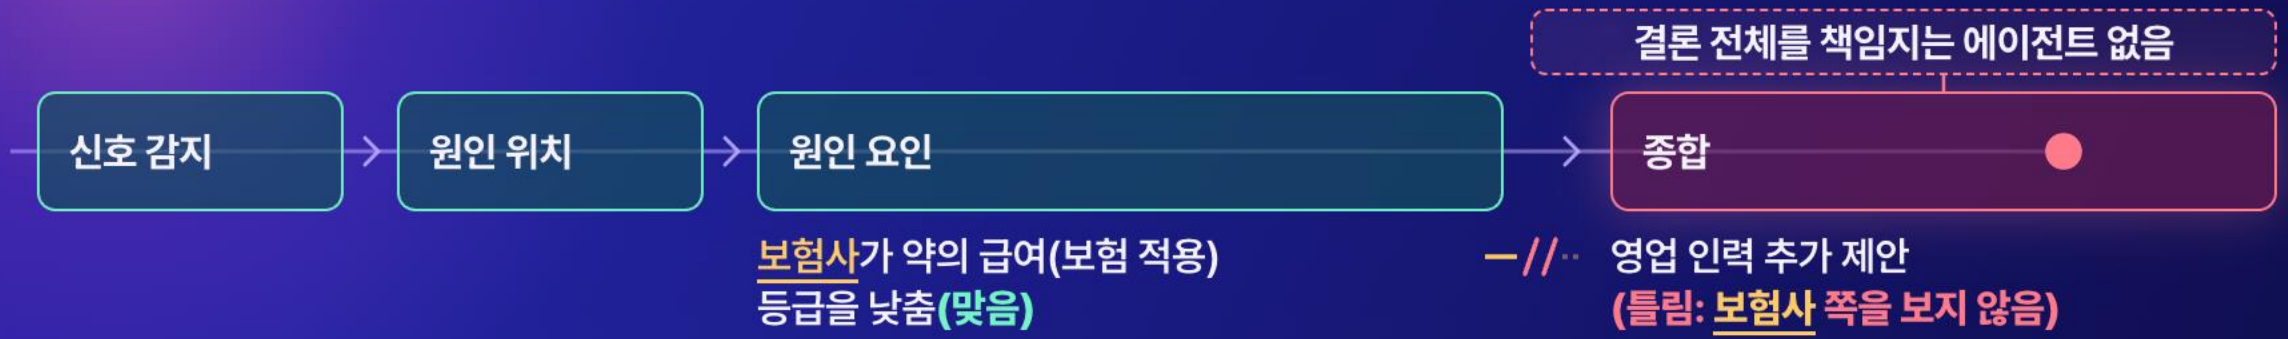
신호 | 원인 | 조치 | 전망

조율 에이전트(오케스트레이터)

네 에이전트에 일을 나눠 주고 서로 잇는 에이전트

예시 답 검토 → 구성 폐기

ZS 발표에서 든 예시 답(한 지역의 처방 감소)



원인은 맞았지만 조치가 틀렸다
결론 전체를 책임지는 에이전트가 없었다

→ 각 단계가 맞아도 결론을 책임지는 자리가 비면 조치가 틀린다

Sethuraman·Asokan(ZS Associates) · Why We Killed Our Multi-Agent Pipeline · 2026-07-02 · 자체 보고(주최 측 자막 확인)

Q 그래서 어떻게 다시 만들었나

신호 감지는 코드 파이프라인으로 옮기고 조사는 에이전트 하나가 맡게 했다

에이전트는 감지된 변화를 조사할 뿐 신호인지는 판단하지 않는다

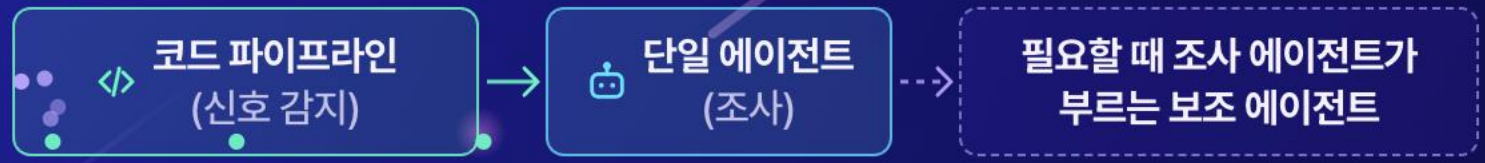
전



조율 1 + 분석 4

→ 정해진 단계는 코드가 먼저, 판단은 한 에이전트가

후



코드 파이프라인 LLM 없이 코드로 짜 같은 입력에 늘 같은 결과를 내는 단계

새 구성의 정확도·비용은 공개되지 않았다

Manoj 외(Rakuten India) · arXiv 2608.18740 · 2026-08-19 · 자체 평가(테스트 환경)

Q 나눠서 정확도가 오른 경우는 없나

에이전트 5개 구성은 단일 에이전트보다 68건 더 풀었고 비용은 2.7배였다

Rakuten 분석 질의 300건(가상 데이터), GPT-4.1. 단일 에이전트는 5개 구성에서 입력 검증만 뺀 것

→ **정답은 68건 늘었고 비용은 2.7배. 이 비용을 낼지는 업무마다 다르다**



Zettl·Gosmar · The Coordination Tax · arXiv 2610.37700 · 2026-10-25 · 통제 실험
(코딩 과제)

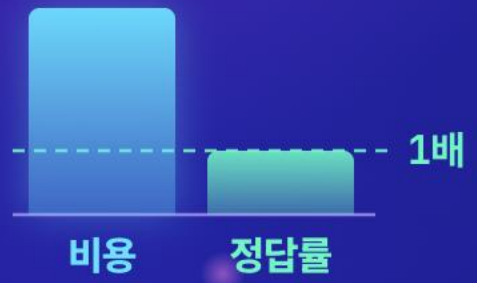
Q 역할을 나누면 늘 정확도가 오르나 — 코딩 과제 실험

계획·코딩·검토로 나누자 비용은 3.22배가 됐고 정답률은 차이가 없었다

코딩 과제 135개(데이터 작업 아님), 구성 6종 중 계획자-코더-검토자, 3회씩, 기준 Opus 5.5 단독

비용

(단독 대비 계획자-코더-검토자)



3.22배

→ 역할을 나눈다고 정확도가 오르지는 않았다

시간 **3.24배**

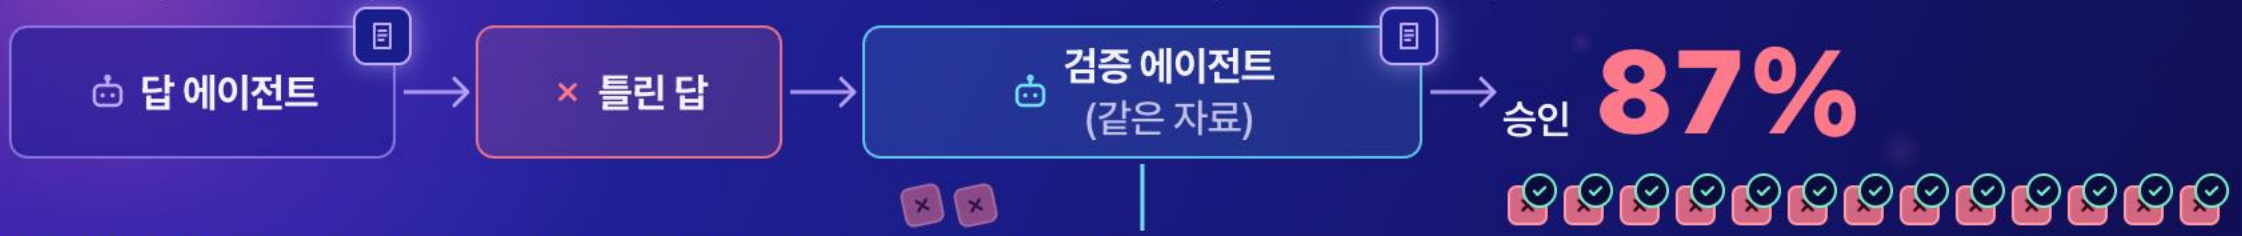
정답률 차이 **-1.5%p**

(통계적으로 의미 있는 차이 아님)

Sourati 외(Oracle AI·USC) · Same Context, Different Agents · arXiv 2610.20959 · 2026-10-14 · 통제 실험

Q 검증 에이전트를 하나 더 붙이면 안전해지나

Oracle AI, 데이터 과제 1,514개·모델 7종. 답 전에 데이터를 직접 조회하는 모델 3종(점수는 정확도 점수)



검증 에이전트 다른 에이전트의 답을 받아 승인하거나 되돌려 보내는 에이전트

같은 실험, 데이터를 보지 않고 답하는 모델: 검증 에이전트를 붙이자 +23점, 비용 4배

검증 에이전트는 틀린 답의 87%를 승인했고 정확도는 5점 내려갔다

→ 같은 자료를 본 검증 에이전트는 같은 오류를 놓친다

Q 나누면 비용이 늘고 정확도는 경우마다 달랐다.
그러면 나눌 때는 어떻게 나누나

규칙 5 RULE 05

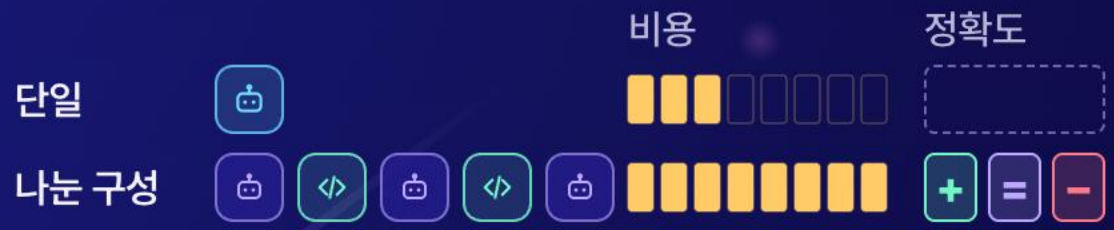
나누기 전에 단일 구성과 비교하고, 나눌 때는 코드 파이프라인 단계를 끼운다

근거: 앞 세 실험(Rakuten·Coordination Tax·Oracle).

참고: ZS

발표자 제안 · 근거 Rakuten(2026-08-19) · Zettl·Gosmar(2026-10-25) · Oracle AI(2026-10-14) · 참고 ZS(2026-07-02) · Thomson Reuters(arXiv 2610.19999, 2026-10-14)

단일 구성과 나눈 구성을 각각 두 번 이상 돌려 비교하고 나은 쪽을 쓴다



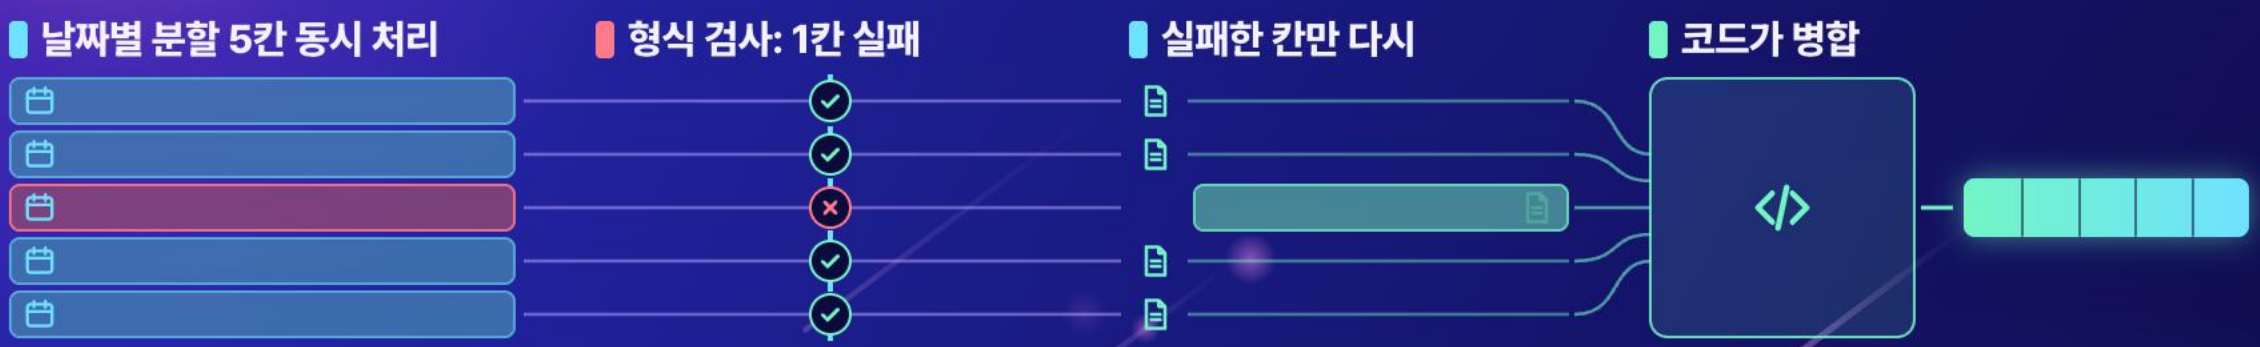
정해진 단계(신호 감지 등)는 코드 파이프라인으로

하네스 구현 제안:
단일 에이전트 결과를 먼저 남겨 비교 기준으로 쓴다

규칙 6 RULE 06

앞 장은 에이전트를 나누는 기준, 이 장은 작업을 나누는 기준. 참고: 분산 처리의 분할·검사·병합 순서

작업은 데이터 단위로 나누고 결과는 정해진 형식으로 받아 코드가 병합한다



결과 파일 없는 분할만 다시(제안) · 하네스 구현: 분할 실행(pipeline)·칸마다 에이전트(agent)·형식 검사(schema)

스키마(출력 형식) 결과에 어떤 항목이 어떤 형식으로 있어야 하는지 정한 규격

06

SECTION 06

실행 기록으로 검증

설계가 맞았는지를 답만이 아니라 실행 기록으로도 확인한다

① 데이터 정의 ✓

② 계산 위치 ✓

③ 나누는 방식 ✓

④ 실행 기록으로 검증

dbt Developer Blog(Lin·Noonan·Ferguson) · Inside the dbt Wizard harness · 2026-10-14 · 판매사 글(개인 플랫폼 7개월 기록)

Q 에이전트가 쓴 코드가 CI를 통과했다면 숫자도 맞나

dbt(데이터 변환 도구) Labs 직원 1명의 개인 트레이딩 데이터 플랫폼, 7개월 기록

자산 239개(dbt 변환 모델 174개)

품질 검사 1,114개

파이프라인 실행 24,388회

병합 PR 405개

dbt 사례: 에이전트 PR 첫 CI 통과

약 90%



에이전트가 코드 대부분을 쓴 개인 데이터 플랫폼에서 에이전트 PR 대부분이 첫 CI를 통과했다

CI 코드를 바꿀 때마다 자동으로 시험을 돌려 기준 미달이면 합치지 못하게 하는 절차

dbt Developer Blog(Lin·Noonan·Ferguson) · Inside the dbt Wizard harness · 2026-10-14 · 판매사 글(개인 플랫폼 7개월 기록)

실행이 오류로 멈추는 결함은 1일 만에 찾았고 실행은 성공하고 숫자만 틀린 결함은 65일 걸렸다

앞 장과 같은 dbt 개인 데이터 플랫폼 7개월 기록. 결함 표본(건수 비공개)에서 발견까지 걸린 날의 중앙값

실행이 오류로 멈추는 결함: 중앙값 1일

중앙값 값을 순서대로 늘어놓았을 때 한가운데 값

실행은 성공하고 숫자만 틀린 결함: 중앙값 65일

원문에서 비용이 가장 컸다고 밝힌 결함은 CI(자동 시험)와 코드 리뷰를 모두 통과했다

→ **CI와 코드 리뷰를 통과한 코드도 틀린 숫자를 냈고, 오류 메시지가 없어 늦게 발견됐다**

Kolli 외(Thumbtack) · Evaluating Enterprise Analytics Agents: An End-to-End, Trace-Backed Methodology · arXiv 2609.09182 · 2026-08-28 · 자체 평가(논문)

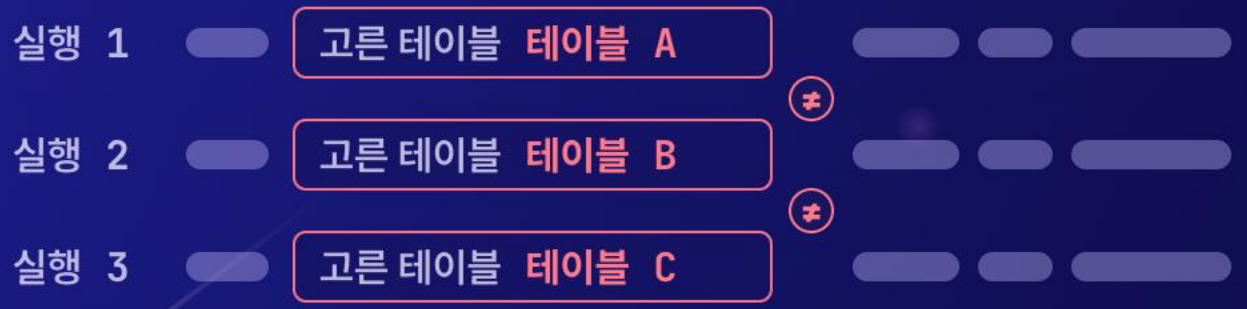
Q 답만 채점하면 무엇이 안 보이나

더 강한 설정 B는 답을 거부하지 않았지만 50문항 중 41문항에서 실행마다 쓴 테이블이나 해석이 달랐다

Thumbtack(미국 생활 서비스 중개) 사내 분석 에이전트에 질문 50개를 3번씩 실행. 설정 A·B는 모델 설정만 다르다

→ 답만 채점하면 안 보이던 것이 기록에 보였다

설명용 예시 같은 질문 1개를 설정 B로 3번 실행한 기록



처음부터 답을 거부한 실행: A 73% → B 0%

실제 데이터로 답한 실행: A 21% → B 73%

B 실행 150개 중 **24개(16%)** 도구 호출 한도 소진

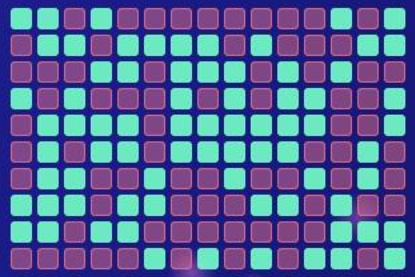
Sait Izmit(Snowflake) · Building GTM AI Agents: Lessons from Deploying to 6,000 Users · 2026-07-02 · 판매사 자체 사례(주최 측 자막 확인)

Q 그러면 무엇부터 준비하나

Snowflake 담당자는 영업 에이전트를 써 보기 전에 평가 질문 150개를 적고 첫 실행 정확도 50%를 확인했다

Snowflake Sait Izmit, 사용자 6,000명 사내 영업 에이전트. 채점 기준 비공개

영업 질문 **150개**



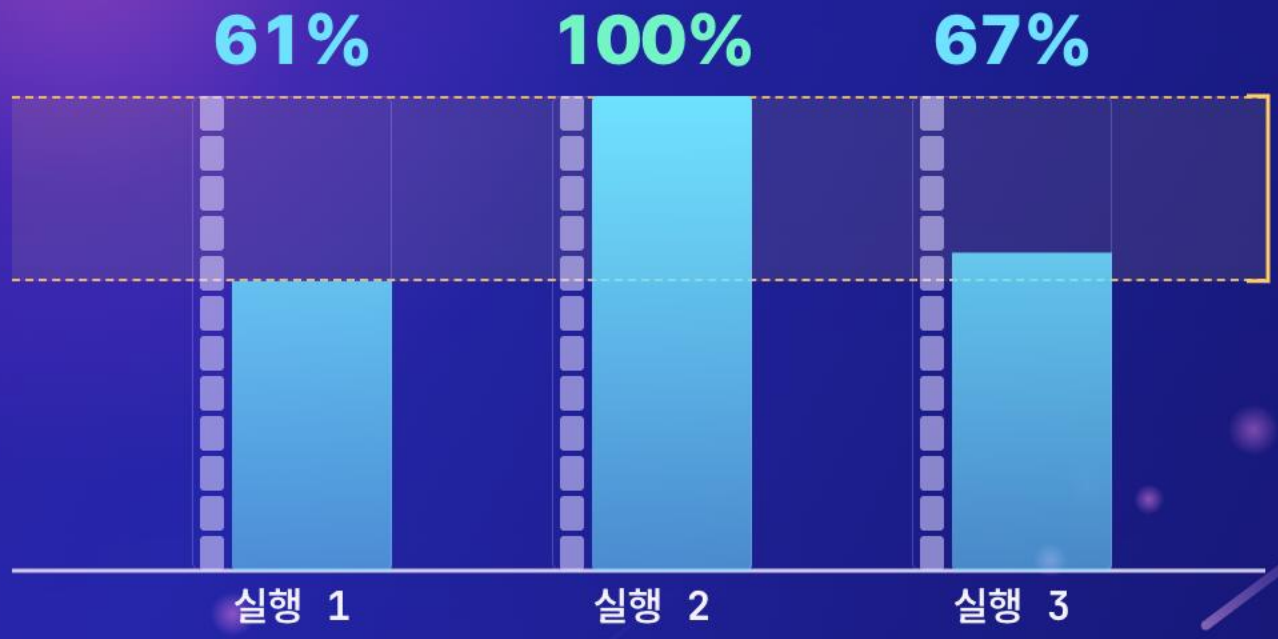
50% 첫 실행 정확도

그 뒤 원칙: 질문 100종을 70%로 맞히기보다 50종을 95%로 맞힌다

→ **질문을 먼저 적었기에 50%가 보였다**

dbt Developer Blog(Alex Noonan) · Do coding agents still need dbt skills? · 2026-10-30 · 판매사 개념 검증(대부분 조건당 1회)

작업 12건의 결과 행을 정답과 비교해 맞은 비율



Q 한 번 측정하면 믿어도 되나

같은 조건을 세 번 돌리자 점수가 61%, 100%, 67%로 달랐다

dbt 블로그 글쓴이(Alex Noonan)의 소규모 실험. Sonnet 5.5 + 스킬, 작업 12건을 3회

저자: 실행 간 차이가 스킬 효과보다 크다

→ 한 번 돌린 결과로는 설계 변경의 효과를 말할 수 없다

Zhu·Pu(East China Normal University) · TelemetrySuffBench · arXiv 2608.07899 · 2026-08-08 · 가상 오류 기록 실험

Q 기록에 무엇을 담아야 하나

중국 화둥사범대학, 오류를 넣은 가상 기록을 모델 5종에 주고 실패 단계 맞히기

실패 시작 단계를 첫 답으로 맞힌 비율

OpenTelemetry 서비스 실행 기록을 남기는 업계 공통 규격. 생성형 AI용 항목은 개발 중

전체 기록(결정 내용 포함) **33.8~97.2%** (모델별)



표준 항목만 **0.5% 이하**



✓ ✓ 실패 유무는 둘 다 거의 다 맞힘

OpenTelemetry 표준 항목만 남긴 실행 기록으로는 실패가 시작된 단계를 거의 찾지 못했다

→ 에이전트가 무엇을 읽고 결정했는지 남겨야 원인 단계를 찾는다

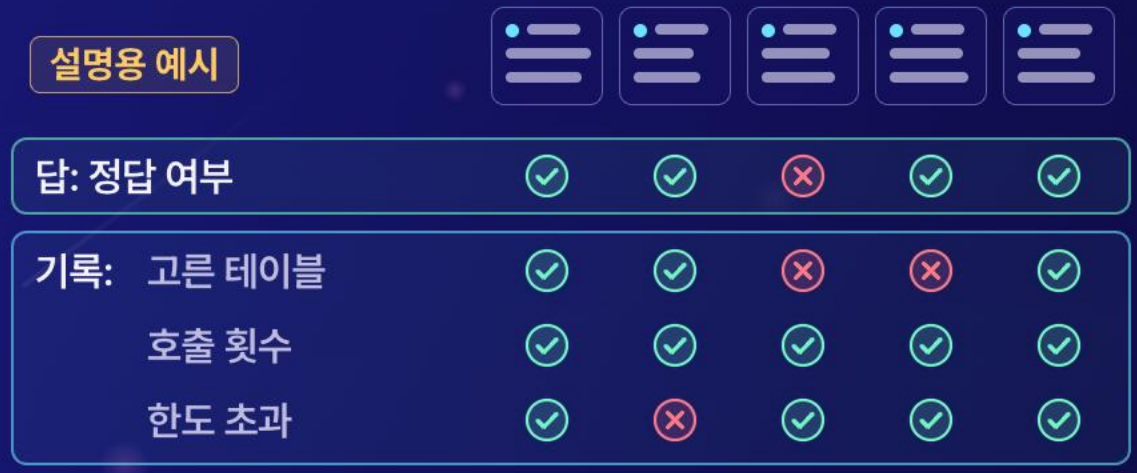
발표자 제안 · 근거 Snowflake(2026-07-02) · Thumbtack(2026-08-28) · revfactory/harness 2.1.0

규칙 7 RULE 07

사용하기 전에 평가 질문을 적고, 답과 함께 실행 기록을 채점한다

근거: Snowflake 150개·50% · Thumbtack: 50문항 중 41문항에서 실행마다 고른 테이블이 다름

설명용 예시



하네스 구현: 단계마다 결과를 파일로 남기고, 사실 확인은 검증 에이전트 여럿이 원 출처를 따로 읽어 과반이 '확인됨'으로 판정한 것만 통과

발표자 제안 · 근거 TelemetrySuffBench(2026-08-08) · dbt 블로그(2026-10-30) · revfactory/harness 2.1.0(harness:evolve는 실제 기능. 기록 표와 입력 확장은 발표자 제안)

규칙 8 RULE 08

읽은 문서·테이블·쿼리·버전을 남기고 같은 결과가 여러 번 실행에서 반복될 때 설계를 바꾼다

근거: 표준 항목만 남긴 기록은 실패 단계 정답 0.5% 이하 · 같은 조건 세 번 61·100·67%

설명용 예시

날짜	과제	스킬 버전	읽은 문서	조회한 테이블	성공	토큰	오류
11-03	매출	v2	정의 A	sales_daily	예	18k	없음
11-04	매출	v3	정의 A	sales_raw	아니요	51k	상한 초과

같은 실패 3회 이상 → 하네스 개선 기능(evolve)에 넣는다(제안)

에이전트가 데이터 작업을 맡을 때 결과에 영향을 준 것은 LLM 바깥의 네 가지였다

① 데이터 정의
사람이 쓰고
데이터 모델과 함께 고친다.
목록부터 차례로 읽는다

② 계산 위치
늘 같은 단계는 코드,
집계는 DB·시맨틱 레이어

③ 나누는 방식
단일 에이전트와 먼저 비교,
정해진 단계는 코드,
작업은 데이터 단위

④ 실행 기록으로 검증 평가 질문 먼저, 답과 기록을 함께 채점, 여러 번 돌린다

→ **LLM을 바꾸지 않고 적용한다**

이 발표의 근거는 2026년 6월 이후 공개된 다음 자료에서 가져왔다 (1/2)

Anthropic 데이터팀 · How Anthropic enables self-service data analytics with Claude · 2026-06-03

KPMG International · Global AI Pulse Q2 2026 · 2026-06-24

Sethuraman·Asokan(ZS Associates) · Why We Killed Our Multi-Agent Pipeline · AI Engineer World's Fair · 2026-07-02

Sait Izmit(Snowflake) · Building GTM AI Agents: Lessons from Deploying to 6,000 Users · AI Engineer World's Fair · 2026-07-02

Majeed 외(NYU 아부다비) · An Empirical Study of MCP Applications · arXiv 2607.25635 · 2026-07-28

Zhu·Pu(East China Normal University) · TelemetrySuffBench · arXiv 2608.07899 · 2026-08-08

Manoj 외(Rakuten India) · A Multi-Agent Platform for Automated Enterprise Analytics and Insight Generation · arXiv 2608.18740 · 2026-08-19

The Modern Data Company 설문(Business Wire·IT Brief) · 2026-08-19/20

MCP 공식 블로그(Soria Parra·Delimarsky) · The New MCP Roadmap · 2026-08-22

Kolli 외(Thumbtack) · Evaluating Enterprise Analytics Agents: An End-to-End, Trace-Backed Methodology · arXiv 2609.09182 · 2026-08-28

Necula(Alexandru Ioan Cuza University) · Can Coding Agents Reproduce Official Statistics? · arXiv 2609.22222 · 2026-09-02

이 발표의 근거는 2026년 6월 이후 공개된 다음 자료에서 가져왔다 (2/2)

데브시스터즈(박현기) · 쿼리가 아니라 정의를 고치기로 했습니다: Databricks Metric View 도입기 · 2026-09-18

KPMG US · Q3 2026 AI Pulse Survey · 2026-09-24

Sehanobish 외(Kensho) · From Benchmarks to Production: A Text-to-SQL System for Complex Financial Data · arXiv 2610.03524 · 2026-10-02

웹케시 발표(ZDNet Korea, 남혁우) · 2026-10-07

Bansal 외(Thomson Reuters) · A Strong Harness Narrows the Model Gap · arXiv 2610.19999 · 2026-10-14

Sourati 외(Oracle AI·USC) · Same Context, Different Agents · arXiv 2610.20959 · 2026-10-14

dbt Developer Blog(Lin·Noonan·Ferguson) · Inside the dbt Wizard harness · 2026-10-14

토스(김문수) · 실행은 도메인별로, 문맥은 한 레포에 · 2026-10-16

CJ올리브영 사례(AWS 기술 블로그) · CJ올리브영의 AI 기반 운영 이슈 분석과 일일 점검 자동화 · 2026-10-16

Zettl·Gosmar · The Coordination Tax · arXiv 2610.37700 · 2026-10-25

dbt Developer Blog(Alex Noonan) · Do coding agents still need dbt skills? · 2026-10-30

발표자 자료: revfactory/harness 2.1.0(2026-09-26)

질문을 받겠습니다

github.com/revfactory/harness

황민호